

Bộ sưu tập các mô hình học sâu cho nhiều nhà máy

Phân loại bệnh trong nông nghiệp thông minh

Hoàng-Tú Võ, Luy1-Dà Quách, Hoàng Trần Ngọc

Khoa Kỹ thuật phần mềm
Đại học FPT, thành phố Cần Thơ, Việt Nam

Tóm tắt–Việc xác định bệnh thực vật ở giai đoạn đầu đóng vai trò quan trọng trong việc đảm bảo quản lý bệnh hiệu quả và bảo vệ mùa màng. Sự xuất hiện của các bệnh thực vật có thể làm giảm đáng kể cả năng suất và chất lượng cây trồng, gây ra thiệt hại tài chính cho nông dân và dẫn đến tình trạng thiếu lương thực cho người tiêu dùng. Các phương pháp phát hiện bệnh truyền thống dựa vào quan sát bằng mắt, có thể tốn nhiều thời gian, công sức và thường không chính xác. Hệ thống phát hiện bệnh tự động dựa trên kỹ thuật máy học có khả năng cải thiện đáng kể độ chính xác và tốc độ phát hiện bệnh. Bài viết này trình bày một mô hình phân loại bệnh thực vật kết hợp đầu ra của hai mô hình học chuyển giao EfficientNetB0 và MobileNetV2 để cải thiện độ chính xác phân loại bệnh. Bộ dữ liệu PlantVillage được sử dụng để đào tạo và thử nghiệm mô hình đang xem xét, trong đó có 54.305 bức ảnh về 38 loại bệnh thực vật khác nhau, đạt tỷ lệ chính xác 99,77% trong phân loại bệnh. Việc sử dụng tập hợp các mô hình học sâu trong nghiên cứu này cho thấy kết quả khả quan, chỉ ra rằng kỹ thuật này có thể nâng cao độ chính xác của việc phân loại bệnh thực vật. Ngoài ra, nghiên cứu này còn góp phần phát triển các hệ thống phát hiện bệnh tự động chính xác và đáng tin cậy, qua đó hỗ trợ nông nghiệp bền vững và an ninh lương thực toàn cầu.

Từ khóa–Học tập theo nhóm; hệ thống phát hiện bệnh tự động; chuyển giao mô hình học tập; bệnh thực vật

I. GIỚI THIỆU

Cây trồng dễ mắc nhiều loại bệnh khác nhau, đặc biệt là ở vùng đồng bằng sông Cửu Long của Việt Nam và trên toàn thế giới. Có nhiều yếu tố góp phần vào sự phát triển và lây lan của bệnh thực vật, bao gồm điều kiện thời tiết, sức khỏe đất đai và sự hiện diện của sâu bệnh [3]. Đồng bằng sông Cửu Long, nằm ở phía Tây Nam Việt Nam, còn được gọi là Miền Tây, khí hậu ẩm ướt và ẩm áp tạo điều kiện lý tưởng cho nhiều loại bệnh thực vật phát triển, có thể gây ra tác động kinh tế và môi trường đáng kể cho nông dân và cộng đồng địa phương [41].

Tương tự như vậy, ở những nơi khác trên thế giới, bệnh thực vật có thể là thách thức lớn đối với nông nghiệp và an ninh lương thực, ảnh hưởng đến năng suất và chất lượng cây trồng. Do đó, việc theo dõi và quản lý bệnh thực vật là rất quan trọng để ngăn ngừa sự lây lan và giảm thiểu tác động của chúng đến sức khỏe thực vật và sản xuất lương thực. Gần đây, ngày càng có nhiều sự quan tâm đến việc sử dụng các kỹ thuật học máy (ML) và học sâu (DL) để cải thiện khả năng chẩn đoán sớm bệnh thực vật. Điều này liên quan đến việc phát triển các thuật toán có thể phân tích các tập dữ liệu lớn về hình ảnh thực vật và phát hiện các dấu hiệu sớm của bệnh, chẳng hạn như thay đổi về màu sắc hoặc kết cấu của lá. Các thuật toán này có thể được đào tạo bằng cách sử dụng các tập dữ liệu được gắn nhãn của cây khỏe mạnh và bị bệnh, cho phép chúng xác định

các kiểu mẫu và đưa ra dự đoán chính xác về sức khỏe của cây. Bằng cách sử dụng các kỹ thuật tiên tiến này, các nhà nghiên cứu hy vọng có thể cải thiện độ chính xác và tốc độ chẩn đoán bệnh, từ đó giúp nông dân thực hiện các biện pháp phòng ngừa và giảm thiểu thiệt hại mùa màng. Đóng góp chính của nghiên cứu này là giới thiệu một mô hình phân loại bệnh thực vật kết hợp đầu ra của hai mô hình học chuyển giao, EfficientNetB0 và MobileNetV2, để cải thiện độ chính xác của phân loại bệnh.

II. TÁC PHẨM LIÊN QUAN

Nhiều nghiên cứu đã tìm hiểu việc sử dụng cả thuật toán phân loại truyền thống và mô hình học sâu tiên tiến trong việc phân loại bệnh lá thực vật. Điều này cho thấy đang có những nỗ lực liên tục nhằm phát triển các phương pháp chính xác và hiệu quả hơn để xác định và chẩn đoán các bệnh ảnh hưởng đến lá cây. Bài báo [30] đề xuất các bộ phân loại ANN và SVM để xác định và phân loại các bệnh nấm với độ chính xác lần lượt là 87% và 91,16%. Nghiên cứu này [14] sử dụng bộ phân loại Máy hỗ trợ vectơ (SVM) để nhận dạng bệnh, đạt tỷ lệ chính xác vượt quá 90%.

Trong nghiên cứu [28], kỹ thuật phân loại SVM được sử dụng và bao gồm việc trích xuất các đặc điểm màu sắc và kết cấu, mang lại độ chính xác phân loại là 88,89%. Bằng cách trích xuất các đặc điểm như màu sắc, hình dạng và kết cấu từ hình ảnh cây cà chua khỏe mạnh và không khỏe mạnh và đưa chúng vào cây phân loại, nghiên cứu [36] đã đạt được độ chính xác phân loại là 97,3% cho sáu loại hình ảnh cà chua. Nghiên cứu [20] kết hợp mạng nơ-ron tích chập (CNN) và phương pháp SVM để trích xuất các đặc điểm và phân loại hình ảnh bệnh lá lúa. Nghiên cứu đạt được độ chính xác phân loại là 96,8%. Nghiên cứu [12] trình bày một mô hình mới để xác định bệnh lá cây, sử dụng Deep CNN được đào tạo với tập dữ liệu mở bao gồm 39 lớp hình ảnh lá cây và nền của chúng. Nghiên cứu đạt được độ chính xác phân loại là 96,46%. Bài báo [44] thảo luận về tính thực tiễn của việc sử dụng CNN để phân loại bệnh thực vật trong hình ảnh lá, mang lại tỷ lệ chính xác là 99,32%. Nghiên cứu [25] giới thiệu một phương pháp mới để xác định bệnh lúa sử dụng các kỹ thuật CNN sâu, đạt tỷ lệ chính xác là 95,48%. Bài báo [48] trình bày một phương pháp mới để phân loại bệnh lá cà chua bằng cách sử dụng CNN sâu kết hợp cơ chế chú ý, đạt tỷ lệ chính xác 99,24% trên tập dữ liệu bệnh lá cà chua. Nghiên cứu này [27] đề xuất một CNN nhỏ gọn cho nhiệm vụ xác định Bệnh cà chua, đạt được điểm F1 là 99,70%. [43] Các bệnh về cà chua đã được xác định và phân loại chính xác bằng Mạng nơ-ron tích chập (CNN), đạt tỷ lệ thành công là 98,49%. Trong thời gian gần đây,

Học chuyển giao đã trở nên phổ biến rộng rãi và đã thành công trong việc giải quyết một số vấn đề với những thành tựu đáng kể. Nhiệm vụ chụp ảnh nông nghiệp [32], [5], [26], [33], [31]; Nhiệm vụ chụp ảnh y tế [34], [2], [47], v.v. Để sử dụng mô hình được đào tạo trước để xác định bệnh thực vật, bài báo này [49] trình bày cách xác định bệnh lá táo với độ chính xác 93,71% bằng cách sử dụng DenseNet-121. Trong nghiên cứu [16], mô hình học sâu VGG16 đã được sử dụng để đạt được độ chính xác 90% trong việc xác định bệnh ở lá trà. Trong bài báo này [45] sử dụng mô hình VGG16 để xác định lá táo bị bệnh với độ chính xác là 90,4%. Trong nghiên cứu này [1], việc xác định hạt ngô đơn bội và lưỡng bội đạt được độ chính xác 94,22% bằng cách sử dụng mô hình VGG-19. Phân loại bệnh cây cà chua được thực hiện trong bài báo này [35] với độ chính xác 97,29% khi sử dụng VGG16 và 97,49% khi sử dụng AlexNet. Nghiên cứu [21] sử dụng phương pháp học chuyển giao với tập dữ liệu làng thực vật để đào tạo lại kiến trúc sâu EfficientNet B7. Sau đó, việc lấy mẫu xuống các tính năng đã thu thập được được thực hiện bằng kỹ thuật hồi quy logistic, đạt độ chính xác 98,7%. Nghiên cứu [13] liên quan đến việc phát hiện bệnh lá cà chua, được thực hiện bằng Densenet-Xception, mang lại độ chính xác là 97,10%. Trong nghiên cứu này [39], các mô hình CNN đã được sử dụng để phân loại các bệnh được tìm thấy ở cây cà chua, đạt độ chính xác 98,6% trên 10 loại bệnh khác nhau. Trong nghiên cứu [42], tỷ lệ thành công trong việc nhận dạng bệnh lá cà chua bằng các mô hình VGG16, InceptionV3 và Resnet50 lần lượt là 99,62%, 99,75% và 99,5%. Mục tiêu của nghiên cứu này [37] là chẩn đoán các bệnh có trong lá cà chua bằng cách phân loại ảnh lá cà chua khỏe mạnh và không khỏe mạnh bằng cách sử dụng hai CNN được đào tạo trước, cụ thể là InceptionV3 và Inception ResNetV2. Nghiên cứu [22] đạt độ chính xác 99,22%.

Trong nghiên cứu này, ba mô hình dựa trên CNN (VGG-16, ResNet-152 và EfficientNet-B4) đã được đề xuất để phân loại bệnh trên lá cà chua. Nghiên cứu cho thấy các mô hình đạt độ chính xác lần lượt là 93,75%, 97,27% và 98%. Với việc sử dụng mô hình DenseNet, bài báo [6] đã đạt được độ chính xác phân loại là 99,9% trong việc xác định bệnh cà chua. Bằng cách tận dụng MobileNetV2, nghiên cứu [24] đã tạo ra một thuật toán nâng cao để nhận dạng bệnh lá táo và đạt được tỷ lệ chính xác là 96,23%. Trong nghiên cứu [4], việc phát hiện bệnh lá cà chua được thực hiện bằng một số mô hình, trong đó MobileNet đạt tỷ lệ chính xác là 94%, Xception là 95,32%, VGG16 là 93,35%, ResNet50 là 96,03%, DenseNet121 là 96,3% và EfficientNetB5 là 99,07%.

III. MÔ HÌNH HỌC CHUYỂN GIAO VÀ HỌC TẬP TỔNG THỂ

A. Mô hình học chuyển giao

Học chuyển giao (TL) [29] là một kỹ thuật trong học máy giúp cải thiện quá trình học bằng cách tận dụng mô hình được đào tạo trước cho một nhiệm vụ mới. Mô hình TL là mạng nơ-ron đã được đào tạo trên một tập dữ liệu lớn, thường được sử dụng cho các tác vụ như nhận dạng hình ảnh hoặc xử lý ngôn ngữ tự nhiên. Các mô hình này sau đó được điều chỉnh và tinh chỉnh cho một nhiệm vụ mới bằng cách sử dụng một tập dữ liệu nhỏ hơn. Nguyên tắc cốt lõi đằng sau việc học chuyển giao dựa trên ý tưởng rằng một mô hình có khả năng nhận dạng các tính năng cụ thể trong một miền có thể được sử dụng lại để xác định các tính năng tương tự trong miền khác.

Trong thời gian gần đây, nhiều mô hình Học sâu khác nhau, bao gồm EfficientNet, MobileNet, VGG, DenseNet, Xception, ResNet,

trong số những người khác, đã giành chiến thắng trong các cuộc thi ILSVRC. Cơ sở dữ liệu ImageNet, chứa hơn 1,4 triệu hình ảnh cho 1000 hạng mục khác nhau, là tập dữ liệu được sử dụng rộng rãi nhất cho các cuộc thi này. Nghiên cứu hiện tại bao gồm sự kết hợp của các mô hình EfficientNetB0 và MobileNetV2 để phân loại bệnh thực vật.

B. Học tập tổng hợp


Học tập tổng hợp (EL) [11] là một phương pháp liên quan đến việc hợp nhất nhiều mô hình riêng biệt để đạt được hiệu suất tổng thể được cải thiện về mặt khái quát hóa. Có một số loại mô hình tổng hợp có thể được sử dụng cho mục đích này, mỗi loại có cách tiếp cận riêng và những ưu điểm cũng như nhược điểm riêng. Một trong những loại mô hình tổng hợp phổ biến nhất là bagging [8], viết tắt của bootstrap aggregating. Kỹ thuật Bagging bao gồm việc đào tạo nhiều mô hình trên các tập hợp dữ liệu riêng biệt, sau đó hợp nhất các dự đoán của chúng thông qua tính trung bình hoặc bỏ phiếu theo đa số. Cách tiếp cận này có thể làm giảm sự thay đổi của các mô hình và tăng cường tính ổn định tổng thể của chúng. Một phương pháp tổng hợp phổ biến khác là tăng cường [10] [9], bao gồm việc đào tạo tuần tự các mô hình yếu và điều chỉnh trọng số của các ví dụ đào tạo để tập trung vào các trường hợp khó nhất. Việc tăng cường có thể có hiệu quả trong việc cải thiện độ chính xác của mô hình và giảm sai lệch. Xếp chồng [46] là một loại EL phức tạp hơn liên quan đến việc đào tạo một số mô hình và sau đó sử dụng một mô hình khác, được gọi là siêu mô hình hoặc máy trộn, để kết hợp các dự đoán của chúng. Cuối cùng, các chiến lược hợp nhất quyết định dựa trên mô hình tổng hợp sâu sử dụng các phương pháp học sâu để kết hợp kết quả của một số mô hình, theo cách phân cấp hoặc song song, nhằm đạt được hiệu suất tốt hơn.

Trong cách tiếp cận của mình, chúng tôi đã sử dụng hai mô hình Học chuyển giao (EfficientNetB0 [40] và MobileNetV2 [15] [38]) nhằm mục đích trích xuất các tính năng sâu từ dữ liệu được cung cấp. Những đặc điểm sâu này sau đó được tích hợp lại với nhau để tạo thành một vectơ đặc điểm duy nhất có nhiều chiều. Những đặc điểm này sau đó được đưa vào một vài lớp đầy đặc để xử lý và chuyển đổi đặc điểm thêm. Cuối cùng, các đặc điểm thu được được sử dụng để thực hiện phân loại. Điều này cho phép chúng tôi tận dụng thế mạnh bổ sung của nhiều mạng sâu khác nhau và nắm bắt được biểu diễn phong phú hơn của dữ liệu đầu vào so với việc sử dụng một mạng sâu duy nhất hoặc các phương pháp trích xuất tính năng truyền thống. Kết quả chứng minh tính hiệu quả của phương pháp của chúng tôi trong việc tận dụng sức mạnh của mô hình TL để phân loại bệnh trên nhiều loại cây.

IV. PHƯƠNG PHÁP

A. Bộ dữ liệu và Chuẩn bị dữ liệu

Bộ dữ liệu được sử dụng trong nghiên cứu này là bộ dữ liệu PlantVillage được giới thiệu lần đầu tiên trong [17], [18]. Bộ dữ liệu PlantVillage bao gồm 54.305 hình ảnh lá cây, cả lá khỏe mạnh và lá bị bệnh, được phân loại thành 38 nhóm khác nhau dựa trên loài và loại bệnh. Hình ảnh bao gồm 14 loại cây trồng và gồm 38 danh mục và có thể được tìm thấy trong Bảng III. Để đào tạo và đánh giá hiệu quả của mô hình đề xuất, tập dữ liệu được chia thành ba nhóm riêng biệt, cụ thể là tập đào tạo, tập kiểm tra và tập xác thực, theo tỷ lệ 60:20:20. Sự phân bố của tập dữ liệu có thể được thấy trong Hình. 1 và các ví dụ về bệnh thực vật



Quả sung. 1. Phân phối tập dữ liệu.

Hình ảnh từ bộ dữ liệu PlantVillage có thể được trình bày trong Hình. 2. Trước khi đào tạo và đánh giá mô hình, các tập dữ liệu dùng để đào tạo, xác thực và thử nghiệm sẽ trải qua các kỹ thuật xử lý trước. Các kỹ thuật này bao gồm việc thay đổi kích thước hình ảnh thành 224x224 và áp dụng chức năng xử lý trước hình ảnh.


B. Mô hình đề xuất

Trong nghiên cứu này, chúng tôi đã sử dụng hai mô hình học chuyển giao (EfficientNetB0 [40] và MobileNetV2 [15] [38]) để trích xuất các tính năng sâu từ dữ liệu đầu vào. Các đặc điểm sâu này sau đó được nối lại với nhau để tạo thành một vectơ đặc điểm. Sau đó, các đặc điểm này được đưa vào một vài lớp dày đặc để xử lý và chuyển đổi đặc điểm thêm. Cuối cùng, các đặc điểm thu được được sử dụng để thực hiện phân loại. Mô hình đề xuất để phân loại bệnh thực vật có thể được thấy trong Hình. 3. Mô hình có hai mạng xương sống chính là “EfficientNetB0” và “MobileNetV2”, cả hai đều tạo ra hình dạng đầu ra là (None, 1280). Các tenxơ đầu ra này sau đó được xử lý bởi hai lớp chuẩn hóa theo lô riêng biệt và đầu ra của chúng được nối với nhau để tạo thành một tenxơ (None, 2560). Tenxơ nối tiếp này sau đó được đưa vào một lớp dày đặc gồm 256 đơn vị, tiếp theo là một lớp loại bỏ với tỷ lệ loại bỏ là 0,5 để ngăn ngừa hiện tượng quá khớp. Cuối cùng, đầu ra của lớp bỏ qua được truyền qua một lớp dày đặc khác với 38 đơn vị, tạo ra đầu ra cuối cùng của mô hình. Tổng số tham số trong mô hình là 6.983.177,


trong đó 6.901.922 cá thể có thể đào tạo được và 81.255 cá thể còn lại không thể đào tạo được. Kiến trúc và mô hình đề xuất có thể được hiển thị trong Hình. Bảng 4 và Bảng 1 thể hiện cách biểu diễn nhiều thông tin khác nhau, bao gồm các lớp của mô hình, hình dạng đầu ra của từng lớp, số lượng tham số có thể đào tạo trong mỗi lớp và tổng số tham số có thể đào tạo trong mô hình. Mô hình được đề xuất cũng sử dụng kỹ thuật lập lịch tốc độ học tập [23] trong quá trình đào tạo của nó. Lên lịch tốc độ học là một kỹ thuật điều chỉnh tốc độ học, giúp kiểm soát kích thước bước của thuật toán tối ưu hóa giảm dần độ dốc trong quá trình đào tạo. Mục đích của kỹ thuật này là cải thiện sự hội tụ của mô hình bằng cách giảm dần tốc độ học theo thời gian. Trong mô hình này, sau hai kỷ nguyên, tốc độ học sẽ giảm đi 0,5 lần để chờ điều chỉnh tốc độ học nếu độ chính xác của quá trình đào tạo không được cải thiện. Để giải quyết tình trạng quá khớp tiềm ẩn trong mô hình, các kỹ thuật chính quy hóa được sử dụng trong kiến trúc này giúp tránh tình trạng quá khớp và cải thiện hiệu suất tổng thể của mô hình, điều này rất quan trọng đối với nhiều ứng dụng thực tế.

C. Các số liệu đánh giá mô hình

Nghiên cứu này đã kiểm tra hiệu quả của các mô hình DL bằng cách sử dụng một loạt các số liệu, bao gồm Độ chính xác, Độ thu hồi, Điểm F1 và Độ chính xác. Độ chính xác được sử dụng để đánh giá hiệu suất chung của các mô hình trong việc dự đoán mục tiêu.



Quả sung. 2. Mẫu bệnh thực vật trong tập dữ liệu plantVillage.




Quả sung. 3. Đề xuất mô hình phân loại bệnh thực vật.

biến đổi. Độ chính xác đo tỷ lệ giữa các kết quả dương tính thực sự với tất cả các dự đoán dương tính, trong khi độ thu hồi đo tỷ lệ giữa các dự đoán dương tính thực sự với tất cả các trường hợp dương tính thực tế trong tập dữ liệu. Điểm F1, kết hợp độ chính xác và khả năng thu hồi, cung cấp góc nhìn cân bằng về hiệu suất của mô hình, đặc biệt là trong các tình huống có các lớp không cân bằng. Bằng cách sử dụng nhiều số liệu đánh giá, chúng tôi đã có được sự hiểu biết toàn diện về hiệu suất của mô hình và thực hiện tốt

đưa ra phán đoán sáng suốt về hiệu quả của nó.

$$\text{Độ chính xác} = \frac{TP + TN}{TP + TN + FP + FN} \quad (1)$$

$$\text{Độ chính xác} = \frac{TP}{TP + FP} \quad (2)$$



Quả sung. 4. Kiến trúc của mô hình đề xuất được sử dụng trong nghiên cứu này.

BẢNG I. CÁC LỚP CỦA MÔ HÌNH ĐỀ XUẤT

Lớp (kiểu)	Hình dạng đầu ra	Tham số #
đầu vào 1 (InputLayer)	[(Không có, 224, 224, 3)]	0
efficientnetb0 (Chức năng)	(Không có, 1280)	4049571
mobilenetv2_1.00_224 (Chức năng)	(Không có, 1280)	2257984
chuẩn_bóa hàng loạt (BatchNormalization)	(Không có, 1280)	5120
chuẩn_bóa hàng loạt 1_(BatchNormalization) nổi	(Không có, 1280)	5120
(Concatenate) dày đặc	(Không có, 2017)	0
(Dense) bỏ qua	(Không có, 256)	655616
(Dropout) dày đặc	(Không có, 256)	0
1 (Dense)	(Không có, 38)	9766
Tổng số tham số: 6.983.177		
Các tham số có thể đào tạo: 6.981.922		
Các tham số không thể đào tạo: 81.255		

D. Kết quả

Bảng II trình bày sự so sánh giữa mô hình được đề xuất với các phương pháp hiện đại về các vấn đề tương tự. Các Bảng bao gồm tên cây, số lượng các loại, số lượng hình ảnh trong tập dữ liệu và phương pháp được sử dụng để phát hiện cùng với tỷ lệ chính xác đạt được. Các Bộ dữ liệu PlantVillage được sử dụng cho cả mục đích đào tạo và thử nghiệm. mô hình được đề xuất, chứa 54.305 bức ảnh của 38 loại khác nhau các loại bệnh thực vật. Theo những phát hiện, mô hình đã được đề xuất, kết hợp đầu ra của hai lần chuyển giao các mô hình học tập, EfficientNetB0 và MobileNetV2, đã đạt được tỷ lệ chính xác là 99,77%, vượt trội hơn tất cả các loại khác các phương pháp được liệt kê trong bảng. Theo kết quả, Phương pháp được đề xuất có tiềm năng cải thiện đáng kể độ chính xác của phân loại bệnh thực vật và cung cấp nhiều hơn Hệ thống phát hiện bệnh tự động đáng tin cậy. Phân loại Báo cáo trình bày các số liệu đánh giá cho từng loại cây trồng. bệnh tật, cùng với các giá trị hỗ trợ cho mỗi lớp được trình bày trong Bảng III. Báo cáo cho thấy mô hình thực hiện xuất sắc, với hầu hết các lớp đạt điểm hoàn hảo số liệu đánh giá. Báo cáo cung cấp những hiểu biết hữu ích về khả năng của mô hình để xác định và phân loại các loại khác nhau của bệnh thực vật. Ma trận nhầm lẫn của đề xuất

Thu hồi = $\frac{TP}{TP + FN}$

(3)

F1 Điểm = $\frac{\text{Độ chính xác} \times \text{Thu hồi}}{\text{Độ chính xác} + \text{Thu hồi}}$

(4)

Trong đó, TP: Đúng Dương tính, TN: Đúng Âm tính, FP: Sai Dương tính, FN: Âm tính giả.

Kết quả mô hình được thể hiện ở Hình. 5 và Hình. 6 trình bày các số liệu đo lường hiệu suất của mô hình đề xuất trong cả giai đoạn đào tạo và xác thực, bao gồm độ mất mát và độ chính xác.

V. KẾT LUẬN

Nghiên cứu được trình bày nhấn mạnh tầm quan trọng của việc xác định kịp thời các bệnh ảnh hưởng đến thực vật và những tổn thất đáng kể có thể xảy ra do sự lây lan không kiểm soát của chúng. Các phương pháp phát hiện bệnh truyền thống thường không chính xác, tốn thời gian và công sức, khiến nông dân khó quản lý cây trồng hiệu quả. Việc sử dụng các hệ thống phát hiện bệnh tự động dựa trên thuật toán học máy mang lại cơ hội tuyệt vời để cải thiện độ chính xác và tốc độ phát hiện bệnh. Mô hình phân loại bệnh thực vật được đề xuất, kết hợp đầu ra của hai mô hình học chuyển giao EfficientNetB0 và MobileNetV2, đã chứng minh được tỷ lệ chính xác là 99,77% trong phân loại bệnh, cho thấy tiềm năng cung cấp các hệ thống phát hiện bệnh tự động đáng tin cậy hơn.

Hơn nữa, kết quả nghiên cứu này đưa ra những dấu hiệu khả quan rằng việc sử dụng tập hợp các mô hình DL có thể nâng cao đáng kể độ chính xác của phân loại bệnh thực vật. Việc phát triển các hệ thống phát hiện bệnh tự động chính xác và đáng tin cậy hơn có vai trò quan trọng trong việc hỗ trợ nông nghiệp bền vững và an ninh lương thực toàn cầu, khiến nghiên cứu này trở thành một đóng góp có giá trị cho lĩnh vực nghiên cứu này.

VI. TÁC PHẨM TƯƠNG LAI

Có một số công trình nghiên cứu trong tương lai có thể được thực hiện dựa trên những phát hiện của nghiên cứu này. Đầu tiên, mô hình có thể được thử nghiệm trên các tập dữ liệu khác nhau chứa hình ảnh về bệnh thực vật để đánh giá tính mạnh mẽ và khả năng khái quát hóa của nó. Điều này sẽ giúp xác định xem mô hình có thể áp dụng cho các loại cây trồng và môi trường khác hay không. Thứ hai, mô hình có thể được tích hợp vào hệ thống giám sát thời gian thực để có thể phát hiện sớm và can thiệp kịp thời. Điều này đòi hỏi phải thiết kế một giao diện để sử dụng mà nông dân và các bên liên quan khác có thể sử dụng.

TÀI LIỆU THAM KHẢO

[1] Yahya Altuntas, . Zafer Comert và Adnan Fatih Kocamaz. Xác định hạt ngô đơn bội và lưỡng bội bằng cách sử dụng mạng nơ-ron tích chập và phương pháp học chuyển giao. Máy tính và Điện tử trong Nông nghiệp, 163:104874, 2019.

[2] Laith Alzubaidi, Mohammed A Fadhel, Omran Al-Shamma, Jinglan Zhang, J Santamar ía, Ye Duan và Sameer R. Oleiwi. Hướng tới hiểu biết tốt hơn về quá trình học chuyển giao trong hình ảnh y khoa: một nghiên cứu điển hình. Khoa học ứng dụng, 10(13):4523, 2020.

[3] Kubilay Kurtulus Bastas. Tác động của biến đổi khí hậu đến an ninh lương thực và bệnh thực vật. Trong Kiểm soát sinh học vi sinh: An ninh lương thực và quản lý sau thu hoạch: Tập 2, trang 1-22. Springer, 2022.

[4] Mohan Bhandari, Tej Bahadur Shahi, Arjun Neupane và Kerry Brian Walsh. Botanix-ai: Xác định bệnh trên lá cà chua bằng mô hình học sâu dựa trên giải thích. Tạp chí Hình ảnh, 9(2):53, 2023.

[5] Petra Bosilj, Erchan Aptoula, Tom Duckett và Grzegorz Cielniak. Chuyển giao kiến thức giữa các loại cây trồng để phân đoạn ngữ nghĩa cây trồng so với cỏ dại trong nông nghiệp chính xác. Tạp chí Robot hiện trường, 37(1):7-19, 2020.

[6] Mohamed Bouni, Badr Hssina, Khadija Douzi, Samira Douzi, và cộng sự. Tác động của mạng nơ-ron sâu được đào tạo trước để dự đoán bệnh lá cà chua. Tạp chí Kỹ thuật Điện và Máy tính, 2023, 2023.

[7] Mohammed Brahimi, Kamel Boukhalfa và Abdelouahab Moussaoui. Học sâu để tìm hiểu bệnh ở cà chua: phân loại và hình dung triệu chứng. Trí tuệ nhân tạo ứng dụng, 31(4):299-315, 2017.

[8] Leo Breiman. Dự đoán túi. Học máy, 24:123-140, 1996.

[9] Leo Breiman. Phân loại vòng cung (có thảo luận và phản hồi của tác giả). Biên niên sử thống kê, 26(3):801-849, 1998.

[10] Yoav Freund và Robert E. Schapire. Một khái quát về lý thuyết quyết định của việc học trực tuyến và ứng dụng để thúc đẩy. Trong Lý thuyết học tính toán: Hội nghị châu Âu lần thứ hai, EuroCOLT'95 Barcelona, Tây Ban Nha, ngày 13-15 tháng 3 năm 1995 Biên bản báo cáo 2, trang 23-37. Springer, 1995.

[11] Mudasir A Ganaie, Minghui Hu, AK Malik, M Tanveer và PN Sug-anthan. Học sâu tổng hợp: Một bài đánh giá. Ứng dụng kỹ thuật của trí tuệ nhân tạo, 115:105151, 2022.

[12] G Geetharamani và Arun Pandian. Xác định bệnh lá cây bằng mạng nơ-ron tích chập sâu chín lớp. Máy tính và Kỹ thuật Điện, 76:323-338, 2019.

[13] Huiqun Hong, Jinfa Lin và Fenghua Huang. Phát hiện và phân loại bệnh ở cà chua bằng cách sử dụng học sâu. Trong Hội nghị quốc tế năm 2020 về Dữ liệu lớn, Trí tuệ nhân tạo và Kỹ thuật Internet vạn vật (ICBAIE), trang 25-29. IEEE, 2020.

[14] Selim Hossain, Rokeya Mumtahana Mou, Mohammed Mahedi Hasan, Sajib Chakraborty và M Abdur Razzak. Nhận dạng và phát hiện bệnh trên lá trà bằng máy hỗ trợ vector. Trong Hội thảo quốc tế lần thứ 14 về Xử lý tín hiệu và các ứng dụng của nó (CSPA) của IEEE năm 2018, trang 150-154. IEEE, 2018.

[15] Andrew G Howard, Menglong Zhu, Bo Chen, Dmitry Kalenichenko, Weijun Wang, Tobias Weyand, Marco Andreetto và Hartwig Adam. Mobilenets: Mạng nơ-ron tích chập hiệu quả cho các ứng dụng thị giác di động. Bản in trước arXiv arXiv:1704.04861, 2017.

[16] Gensheng Hu, Haoyu Wu, Yan Zhang và Mingzhu Wan. Một phương pháp học tập cấp thấp để xác định bệnh trên lá trà. Máy tính và Điện tử trong Nông nghiệp, 163:104852, 2019.

[17] David Hughes, Marcel Salathe và cộng sự. Kho lưu trữ hình ảnh mở về sức khỏe thực vật giúp phát triển công nghệ chẩn đoán bệnh di động. Bản in trước arXiv arXiv:1511.08060, 2015.

[18] David P. Hughes và Marcel Salathe. Kho lưu trữ hình ảnh mở về sức khỏe thực vật giúp phát triển chẩn đoán bệnh di động thông qua máy học và huy động cộng đồng. CoRR, tuyệt đối/1511.08060, 2015.

[19] Seyed Mohamad Javidan, Ahmad Banakar, Keyvan Asefpour Vakilian và Yiannis Ampatzidis. Chẩn đoán bệnh lá nho bằng cách sử dụng phương pháp phân cụm k-means tự động và máy học. Công nghệ nông nghiệp thông minh, 3:100081, 2023.

[20] Phùng Giang, Dương Lộ, Vũ Thần, Địch Thái, Công Pháp Lý. Nhận dạng hình ảnh của bốn loại bệnh trên lá lúa dựa trên máy học sâu và máy hỗ trợ vector. Máy tính và Điện tử trong Nông nghiệp, 179:105824, 2020.


[21] Prabhjot Kaur, Shilpi Harnal, Rajeev Tiwari, Shuchi Upadhyay, Surbhi Bhatia, Arwa Mashat và Aliaa M Alabdali. Nhận dạng bệnh ở lá bằng mạng nơ-ron tích chập lai bằng cách áp dụng giảm đặc điểm. Cảm biến, 22(2):575, 2022.

[22] Aima Khalid, Shahzad Akbar, Syed Ale Hassan, Saba Firdous và Sahar Gull. Phát hiện bệnh lá cà chua bằng mạng nơ-ron tích chập sâu. Trong Hội nghị quốc tế lần thứ 4 năm 2023 về những tiến bộ trong khoa học tính toán (ICACS), trang 1-6. IEEE, 2023.


[23] Jinia Konar, Prerit Khandelwal và Rishabh Tripathi. So sánh các kỹ thuật lập lịch tốc độ học khác nhau trên mạng nơ-ron tích chập. Trong Hội nghị sinh viên quốc tế về khoa học điện, điện tử và máy tính (SCEECs) của IEEE năm 2020, trang 1-5. IEEE, 2020.

[24] Tống Lưu, Hạo Nhiên BAI, Phụng Mai Lý, Đồng Vệ Vương, Vũ Huy Chính, Thu Bằng Giang, Phụng Ba Tôn. Mô hình nhận dạng bệnh lá táo để bảo vệ an toàn thực phẩm cho táo. Khoa học và Công nghệ Thực phẩm, 43, 2023.

[25] Dương Lộ, Thư Quyền Nghi, Niễn Ân Tăng, Lưu Ngọc Dung, Vĩnh Chương. Xác định bệnh ở lúa bằng mạng nơ-ron tích chập sâu. Điện toán thần kinh, 267:378-384, 2017.



Quả sung. 5. Ma trận nhầm lẫn của mô hình được đề xuất.



Hình 6. Biểu đồ mất mát và độ chính xác của mô hình được đề xuất.

BẢNG II. SO SÁNH MÔ HÌNH ĐỀ XUẤT CỦA CHÚNG TÔI VỚI CÁC PHƯƠNG PHÁP HIỆN ĐẠI TRÊN CÁC VẤN ĐỀ TƯƠNG TỰ

Nghiên cứu	Bộ dữ liệu / Tên cây	Số lượng của các lớp học	Số lượng của hình	Phương pháp sử dụng	Sự chính xác
[12]	Bệnh lá cây	39	ảnh	Mô hình CNN	96,46%
[44]	Bệnh đậu nành	4	61.486	Mô hình CNN	99,32%
[25]	Bộ dữ liệu bệnh lúa	10		Mô hình CNN	95,48%
[48]	Cây cà chua	10	12.673	Mô hình CNN	99,24%
[27]	Bộ dữ liệu cây trồng cà chua của PlantVillage	10	500	Mô hình CNN	99,70%
[43]	Bộ dữ liệu cây trồng cà chua của PlantVillage	10	4.585	Mô hình CNN	98,49%
[49]	Bệnh lá táo		18.160	Mạng lưới dây đặc-121	93,71%
[45]	Bộ dữ liệu cây trồng táo của PlantVillage	6 4	3.000 2.462 2.000	VGG16	90,40%
[35]	Bộ dữ liệu lá cà chua của PlantVillage	7	13.262	AlexNet VGG16	97,49% 97,23%
[21]	Bộ dữ liệu bệnh lá nho	4	9.027	Hiệu quảNet B7	98,70%
[13]	Cây cà chua		-	Densenet Xception	97,10%
[39]	Cây cà chua	9 10	17.929	Mô hình CNN	98,60%
[42]	Cây cà chua	10	19.553	VGG19	99,62%
				Inception-V3	99,75%
				Resnet50	99,50%
[37]	Cây cà chua (PlantVillage và Field)	3	5,225	Khởi đầu V3	99,22%
				Khởi đầu ResNet V2	99,22%
[22]	Cây cà chua	10	5.524	ResNet-152	93,75%
				Hiệu quảNet-B4	97,27%
				VGG-16	98,00%
	Bệnh lá cà chua	10	7,301	Mạng lưới dây đặc	99,80%
[6] [24]	Bệnh lá táo	9	11,100	MobileNetV2	96,23%
[4]	Bệnh lá cà chua	10	11.000	Hiệu quảNetB5	99,07%
				Mạng di động	94,00%
				Ngoại lệ	95,32%
				VGG16	93,35%
				ResNet50	96,03%
				Mật độ mạng121	96,30%
[19]	Bệnh lá nho	4	3,885	Mạng Google	94,05%
[7]	Bệnh lá cà chua	9	14.828	Mạng Google	99,18%
				AlexNet	98,66%
Nghiên cứu này	PlantVillage Dataset	38	54.305	Hiệu quảNetB0 + MobileNetV2	99,77%

BẢNG III. BÁO CÁO PHÂN LOẠI

#	Kiểu	Lớp học	Độ chính	Thu hồi	Hỗ trợ Độ chính	xác Điểm F1	
C1 Táo		Bệnh ghê	xác 1.00	1,00	1,00	100%	126
C2 Táo		Thối đen	1,00	1,00	1,00	100%	124
C3 Táo		Ri sét táo tuyết tùng	1,00	1,00	1,00	100%	55
C4 Táo		Khỏe mạnh	1,00	1,00	1,00	100%	329
C5 Quả việt quất		Khỏe mạnh	1,00	1,00	1,00	100%	300
C6 Cherry (bao gồm cả chua) Bệnh phần trắng			1,00	1,00	1,00	100%	211
C7 Cherry (bao gồm cả chua) Lành mạnh			1,00	0,99	1,00	99,42%	171
C8 Ngô (bắp)		Đốm lá Cercospora Đốm lá xám	0,95	0,97	0,96	97,09%	103
C9 Ngô (bắp)		Ri sét thông thường	1,00	1,00	1,00	100%	239
C10 Ngô (bắp)		Bệnh cháy lá phía Bắc	0,98	0,97	0,98	97,46%	197
C11 Ngô (bắp)		Khỏe mạnh	1,00	1,00	1,00	100%	232
Nho C12		Thối đen	1,00	1,00	1,00	100%	236
C13 Nho		Esca (Sởi đen)	1,00	1,00	1,00	100%	277
Nho C14		Bệnh cháy lá (Đốm lá Isariopsis)	1,00	1,00	1,00	100%	215
C15 Nho		Khỏe mạnh	1,00	1,00	1,00	100%	84
C16 Cam		Haunglongbing (Citrus Greening)	1,00	1,00	1,00	100%	1101
C17 Đào		Đốm vi khuẩn	1,00	1,00	1,00	100%	460
C18 Đào		Khỏe mạnh	1,00	0,99	0,99	98,61%	72
C19 Hạt tiêu, Chuông		Đốm vi khuẩn	1,00	1,00	1,00	100%	199
C20 Ớt, Chuông		Khỏe mạnh	1,00	1,00	1,00	100%	295
C21 Khoai tây		Bệnh héo rũ sớm	1,00	1,00	1,00	100%	200
C22 Khoai tây		Bệnh mốc sương muộn	1,00	1,00	1,00	100%	200
C23 Khoai tây		Khỏe mạnh	1,00	1,00	1,00	100%	31
C24 Mâm xôi		Khỏe mạnh	1,00	1,00	1,00	100%	74
C25 Đậu nành		Khỏe mạnh	1,00	1,00	1,00	99,9%	1018
Bóng quần C26		Bệnh phần trắng	1,00	1,00	1,00	100%	367
C27 Đậu tây		Cháy lá	1,00	1,00	1,00	100%	222
C28 Đậu tây		Khỏe mạnh	1,00	1,00	1,00	100%	91
C29 Cà chua		Đốm vi khuẩn	1,00	1,00	1,00	99,76%	425
C30 Cà chua		Bệnh héo rũ sớm	0,99	0,99	0,99	99,5%	200
C31 Cà chua		Bệnh mốc sương muộn	1,00	0,98	0,99	98,43%	382
C32 Cà chua		Khuôn Lá	1,00	1,00	1,00	100%	190
C33 Cà chua		Đốm lá Septoria	1,00	1,00	1,00	100%	354
C34 Cà chua		Nhện đỏ Nhện đỏ hai đốm	1,00	1,00	1,00	100%	335
C35 Cà chua		Điểm mục tiêu	1,00	1,00	1,00	99,64%	281
C36 Cà chua		Virus gây bệnh xoắn vàng lá cà chua	1,00	1,00	1,00	99,91%	1072
C37 Cà chua		Virus khảm cà chua	1,00	1,00	1,00	100%	75
C38 Cà chua		Khỏe mạnh	0,99	1,00	1,00	100%	318

[26] Chhaya Narvekar và Madhuri Rao. Phân loại hoa bằng CNN và chuyển giao kiến thức theo góc nhìn nông nghiệp của CNN. Năm 2020 thứ 3 Hội nghị quốc tế về hệ thống bền vững thông minh (ICISS), trang 660-664. IEEE, 2020. ..

[27] Emre Ozbilge, Mehtap Koce Uluk ok, OnsenToygaz và Ebru Ozbilge. Nhận dạng bệnh ở cà chua bằng mạng nơ-ron tích chập nhỏ gọn. Truy cập IEEE, 10:77213-77224, 2022.

[28] Pranjali B Padol và Anjali A Yadav. Phân loại Svm dựa trên lá nho phát hiện bệnh. Hội nghị năm 2016 về những tiến bộ trong xử lý tín hiệu (CASP), trang 175-179. Tạp chí IEEE, 2016.

[29] Sinno Jialin Pan và Qiang Yang. Một cuộc khảo sát về học chuyển giao. IEEE Giao dịch về Kiến thức và kỹ thuật dữ liệu, 22(10):1345-1359, 2010.

[30] Jagadeesh D Pujari, Rajesh Yakkundimath và Abdulmunaf S Byadgi. Phân loại các triệu chứng bệnh nấm ảnh hưởng đến ngũ cốc bằng cách sử dụng đặc điểm kết cấu màu sắc. Tạp chí quốc tế về xử lý tín hiệu, hình ảnh Xử lý và Nhận dạng Mẫu, 6(6):321-330, 2013.

[31] Luy1-Da Quach, Nguyễn Quốc Khang, Anh Nguyễn Quỳnh, và Trần Ngọc Hoàng. Đánh giá hiệu quả của việc tối ưu hóa Thuật toán học chuyển giao trên tập dữ liệu bệnh lá lúa. Tạp chí quốc tế về khoa học máy tính tiên tiến và ứng dụng, 13(10), 2022.

[32] Luy1-Da Quach, Nghi Phạm-Quốc, Đức Chung Trần, và Mohd Fadzil Hassan. Xác định bệnh ở gà bằng vggnet và Mô hình Resnet. Trong Mạng công nghiệp và Hệ thống thông minh: EAI lần thứ 6 Hội nghị quốc tế, INISCOM 2020, Hà Nội, Việt Nam, ngày 27 tháng 8-28, 2020, Biên bản báo cáo 6, trang 259-269. Springer, 2020.

[33] Luy1-Da Quách, Nghi Phạm Quốc, Nhiên Huỳnh Thị, Đức Chung Trần, và Mohd Fadzil Hassan. Sử dụng surf để cải thiện mô hình resnet-50 cho Thuật toán nhận dạng bệnh gia cầm. Trong Hội nghị quốc tế năm 2020 về Trí tuệ tính toán (ICCI), trang 317-321. IEEE, 2020.

[34] Maithra Raghu, Chiyan Zhang, Jon Kleinberg và Samy Bengio. Truyền mẫu: Hiểu về quá trình học chuyển giao trong chẩn đoán hình ảnh y khoa. Những tiến bộ trong hệ thống xử lý thông tin thần kinh, 32, 2019.

[35] Aravind Krishnaswamy Rangarajan, Raja Purushothaman và Anirudh Ramesh. Phân loại bệnh cây cà chua bằng cách sử dụng học sâu được đào tạo trước thuật toán học tập. Khoa học máy tính Procedia, 133:1040-1047, 2018.

[36] H Sabrol và K Satish. Phân loại bệnh cây cà chua dưới dạng kỹ thuật số hình ảnh sử dụng cây phân loại. Trong hội nghị quốc tế năm 2016 về truyền thông và xử lý tín hiệu (ICCSF), trang 1242-1246. Tạp chí IEEE, 2016.

[37] Alaa Saeed, AA Abdel-Aziz, Amr Mossad, Mahmoud A Abdelhamid, Alfadh1 Y Alkhaled và Muhammad Mayhoub. Phát hiện thông minh bệnh lá cà chua sử dụng học chuyển giao dựa trên mạng nơ-ron tích chập mạng lưới. Nông nghiệp, 13(1):139, 2023.

[38] Mark Sandler, Andrew Howard, Menglong Zhu, Andrey Zhmoginov và Liang-Chieh Chen. Mobilenetv2: Giá trị dư ngược và nút thắt tuyến tính. Trong Biên bản báo cáo hội nghị IEEE về thị giác máy tính và nhận dạng mẫu, trang 4510-4520, 2018.

[39] Parul Sharma, Yash Paul Singh Berwal và Wiqas Ghai. Phân tích hiệu suất của mô hình CNN học sâu để phát hiện bệnh ở thực vật bằng cách phân đoạn hình ảnh. Xử lý thông tin trong nông nghiệp, 7(4):566-574, 2020.

[40] Mingxing Tan và Quốc Lê. Efficientnet: Xem xét lại khả năng mở rộng mô hình cho mạng nơ-ron tích chập. Trong Hội nghị quốc tế về máy học, trang 6105-6114. PMLR, 2019.

[41] Nguyễn Viết Thanh và Nguyễn Giác Trí. Phát triển nông nghiệp bền vững, thích ứng với biến đổi khí hậu, chuyển đổi số ở Đồng bằng sông Cửu Long, Việt Nam. Quản sự, 12(2):7548-7560, 2022.

[42] Kai Tian, Jiefeng Zeng, Tianci Song, Zhuliu Li, Asenso Evans và Jiuhao Li. Nhận dạng bệnh trên lá cà chua dựa trên mạng nơ-ron tích chập sâu. Tạp chí Kỹ thuật Nông nghiệp, 54(1), 2023.

[43] Naresh K Trivedi, Vinay Gautam, Abhineet Anand, Hani Moaiteq Al-jahdali, Santos Gracia Villar, Divya Anand, Nitin Goyal và Seifedine

Kadry. Phát hiện sớm và phân loại bệnh trên lá cà chua bằng mạng nơ-ron sâu hiệu suất cao. Cẩm biển, 21(23):7987, 2021.

[44] Serawork Wallelign, Mihai Polceanu và Cedric Buche. Xác định bệnh ở cây đậu nành bằng mạng nơ-ron tích chập. Trong hội nghị FLAIRS, trang 146-151, 2018.

[45] Quan Vương, Vũ Tôn, và Kiến Tâm Vương. Ước tính mức độ nghiêm trọng của bệnh thực vật dựa trên hình ảnh tự động bằng cách sử dụng học sâu. Trí thông minh tính toán và khoa học thần kinh, 2017, 2017.

[46] David H. Wolpert. Tổng quát hóa xếp chồng. Mạng nơ-ron, 5(2):241-259, 1992.

[47] Hạng Vũ, Kiến Vương, Thanh Kỳ Hồng, Ra-ga-tô-cư, Thủy Hoa Vương, Vu Đông Trường. Chuyển giao học tập để phân tích hình ảnh y tế: Một cuộc khảo sát. Điện toán thần kinh, 489:230-254, 2022.

[48] Thánh Nghi Triệu, Văn Bằng, Lưu Cát Chiến, Sóc Ngô. Chẩn đoán bệnh lá cà chua dựa trên mạng nơ-ron tích chập cải tiến bằng mô-đun chú ý. Nông nghiệp, 11(7):651, 2021.

[49] Ung Trung và Minh Triệu. Nghiên cứu về học sâu trong nhận dạng bệnh lá táo. Máy tính và Điện tử trong Nông nghiệp, 168:105146, 2020.